exp_0224 ARCHITECTURE

exp_0224: No-VQ Encoder LoRA / Decoder LoRA — 原理、架構與實驗設計

> 實驗日期：2026-02-23 ～ 2026-02-24 作者：自動產生（exp_0224）

一、實驗動機與背景

1.1 核心研究問題

> **VQ 量化瓶頸是否為制約語音增強品質的主因？**

從 exp_0206 → exp_0217 → exp_0223 的實驗歷程，我們發現兩條改進路線都遇到難以突破的天花板：

實驗	方法	瓶頸
exp_0217	Encoder LoRA（有 VQ 量化）	Feature MSE 下降但 PESQ 不升
exp_0223 v1	Decoder LoRA + MSE only	Silence collapse（方向性錯誤）
exp_0223 v2	Decoder LoRA + MR-STFT + Mel	val_mel 0.84 < noisy 1.21（有改善）

共同瓶頸假設：VQ 量化（K=4096）在 encoder output → decoder input 之間引入不可逆的離散化誤差，使得：

1. Encoder 端：feature MSE 與 VQ commitment loss 耦合，梯度信號被稀釋
2. Decoder 端：即使 decoder 學習適應 student VQ tokens，token 本身已丟失連續分佈的精細信息

exp_0224 提出 **跳過 VQ**，直接讓 encoder 的連續輸出 `[B, 512, T]` 餵入 decoder，以此量化 VQ 瓶頸帶來的損失。

1.2 實驗對比矩陣

```
          |  Decoder Frozen       |  Decoder LoRA (rank=32)
----------|-----------------------|-----------------------------
有 VQ     |  exp_0217             |  exp_0223 (v1/v2)
          |  Encoder LoRA         |  Encoder+VQ frozen
          |  → feature MSE 訓練   |  → 波形重建 loss 訓練
----------|-----------------------|-----------------------------
無 VQ     |  exp_0224a  ← 本實驗  |  exp_0224b ← 本實驗
          |  Encoder LoRA         |  Encoder frozen (from 0217)
          |  → 波形重建 loss 訓練 |  → Decoder LoRA 波形重建
```

這形成一個 2×2 的完整消融實驗，可以獨立量化 VQ 瓶頸和 Decoder LoRA 各自的貢獻。

二、系統架構

2.1 exp_0224a：Encoder LoRA + No-VQ + Decoder Frozen

```
                          ┌──────────── Loss ────────────┐
                          │  wav MSE + MR-STFT + Mel     │
                          └──────────┬──────────┬────────┘
                                     │          │
Noisy Audio [B,1,T]                  ▼          ▼
     │                            recon_wav   clean_wav
     ▼
┌──────────────────────┐
│   Student Encoder    │
│   + LoRA (r=64)      │  ← 可訓練（繼承 exp_0217 weights）
│   α=128              │
└──────────┬───────────┘
           │
           ▼
student_encoder_out [B, 512, T_frame]
           │
           │  ← 連續特徵，跳過 VQ!
           │
           ▼
┌──────────────────────┐
│   WavTokenizer       │
```

```
│   Decoder Backbone   │  ← 完全 Frozen
│   (ConvNeXt × 12)    │
│   + FourierHead      │
└──────────┬──────────┘
           │
           ▼
     recon_wav [B, 1, T_wav]
```

關鍵特性： - VQ 層（K=4096, dim=512）完全跳過，不執行量化 - Encoder LoRA 從 exp_0217 best checkpoint 初始化 - Decoder 使用原始 WavTokenizer pretrained weights - `decode_continuous()` 繞過 `@torch.inference_mode`，讓梯度可以流回 encoder

2.2 exp_0224b：Encoder Frozen + No-VQ + Decoder LoRA

```
                          ┌──────────── Loss ────────────┐
                          │  wav MSE + MR-STFT + Mel     │
                          └──────────┬──────────┬────────┘
                                     │          │
Noisy Audio [B,1,T]                  ▼          ▼
     │                          recon_wav   clean_wav
     ▼
┌──────────────────────┐
│   Student Encoder    │
│   + LoRA (r=64)      │  ← 完全 Frozen（from exp_0224a best）
│   α=128              │
└──────────┬──────────┘
           │
           ▼
student_encoder_out [B, 512, T_frame]
           │
           │  ← 連續特徵，跳過 VQ!
           │      .detach() 截斷梯度
           ▼
┌──────────────────────┐
│   WavTokenizer       │
│   Decoder Backbone   │
│   (ConvNeXt × 12)    │
│   pwconv1: + LoRA    │  ← 可訓練 (r=32, α=64)
│   pwconv2: + LoRA    │  ← 可訓練
│   + FourierHead      │  ← Frozen
└──────────┬──────────┘
```

```
            |
            ▼
      recon_wav [B, 1, T_wav]
```

關鍵特性： - Encoder LoRA 完全 frozen，使用 exp_0224a 訓練好的 weights - 梯度只流過 Decoder LoRA 參數 - `student_encoder_out.detach()` 截斷反向傳播 - 實驗依賴順序：必須先完成 exp_0224a

2.3 模型參數統計

模組	參數量	exp_0224a	exp_0224b
WavTokenizer Encoder	~40.3M	LoRA 可訓練	Frozen
Encoder LoRA (r=64)	~4.72M	✅ 可訓練	❄️ Frozen
VQ Codebook (K=4096)	~2.1M	❄️ Frozen (unused)	❄️ Frozen (unused)
Decoder Backbone (ConvNeXt×12)	~84.8M	❄️ Frozen	LoRA 可訓練
Decoder LoRA (r=32)	~2.36M	—	✅ 可訓練
FourierHead	~39.4M	❄️ Frozen	❄️ Frozen
可訓練合計		~4.72M	~2.36M

三、Loss 設計

3.1 複合損失函數

exp_0224 的 loss 設計與 exp_0223 v2 完全一致，由三個互補的損失項組成：

$$\mathcal{L}_{total} = \lambda_{wav} \cdot \mathcal{L}_{MSE} + \lambda_{stft} \cdot \mathcal{L}_{MR\text{-}STFT} + \lambda_{mel} \cdot \mathcal{L}_{Mel}$$

其中 $\lambda_{wav} = 1.0$、$\lambda_{stft} = 1.0$、$\lambda_{mel} = 45.0$。

3.2 MSE Loss（波形域）

$$ \mathcal{L}_{\text{MSE}} = \frac{1}{T} \sum_{t=1}^{T} \left(\hat{x}(t) - x(t) \right)^2 $$

- **作用**：逐樣本點對齊，提供全域形狀約束
- **問題**：單獨使用會導致 silence collapse（exp_0223 v1 的教訓）
- **加權**：λ = 1.0（輔助角色，非主導）

3.3 Multi-Resolution STFT Loss（頻譜域）

用三種不同的「視窗大小」同時觀察頻譜，各自有不同側重：

```
解析度 1:  n_fft=2048, hop=512,  win=2048  → 頻率解析度高，適合辨識基頻/諧波
解析度 2:  n_fft=1024, hop=256,  win=1024  → 頻率與時間兼顧
解析度 3:  n_fft=512,  hop=128,  win=512   → 時間解析度高，適合捕捉快速瞬態
```

每個解析度各算兩個子損失，再加總：

① Spectral Convergence (SC)：量化「頻譜形狀」整體差距

```
          ‖ |S_clean| - |S_recon| ‖_F          ← 各頻率的幅度差（Frobenius norm）
L_SC = ──────────────────────────────
                ‖ |S_clean| ‖_F                ← 除以 clean 的幅度作正規化
```

→ 值越小代表 recon 的頻譜「輪廓」越像 clean；對頻譜整體能量分布敏感。

② Log Magnitude (LogMag)：在對數尺度比較幅度

```
L_LogMag = mean( | log|S_clean| - log|S_recon| | )
```

→ 對數尺度讓低能量頻段（如安靜段）和高能量頻段（如母音）受同等重視， 避免大能量段主導梯度。

三個解析度平均：

```
L_MR-STFT = (1/3) × Σ_r [ L_SC(r) + L_LogMag(r) ]
```

- **作用**：補足 MSE 無法偵測的頻譜塌縮、諧波失真、時序錯位
- **加權**：λ = 1.0

3.4 Mel Spectrogram L1 Loss（感知域）

先把波形轉換成 Mel 頻譜，再在**對數 Mel 尺度**上做 L1 比較：

```
步驟 1: audio → STFT（n_fft=1024, hop=256）→ 幅度頻譜 |S|
步驟 2: |S| × Mel filterbank（100 個 mel 頻帶）→ Mel 幅度
步驟 3: 取對數 → log-Mel（模擬人耳的對數感知）
步驟 4: 計算 recon 與 clean 的 log-Mel 差距

L_Mel = mean( | log-Mel(recon) - log-Mel(clean) | )
        ↑ 對 100 個 mel 頻帶 × 所有時間幀取平均
```

為什麼用 Mel 而不直接用 STFT？ - 線性頻率的 STFT 中，高頻佔了大多數 bin，但人耳對低頻更敏感 - Mel 濾波器組模擬人耳的非線性頻率感知（低頻密集、高頻稀疏） - 結果：語音基頻和共振峰（決定音色/清晰度的頻段）得到更多監督

為什麼 λ=45？ - 直接沿用 WavTokenizer 原始訓練設定的 `mel_loss_coeff=45` - 使 Mel loss 在數值上主導 total loss（~85%），確保感知品質優先 - 副作用：val_total 的最佳 epoch 由 Mel loss 決定（不是 val_mse）

3.5 為什麼不用 GAN Loss？

項目	GAN (MPD+MRD+DAC)	MR-STFT + Mel
參數量	126.8M 判別器	0（純函數計算）
GPU 記憶體	+4-6 GB	+~0
訓練穩定性	G/D 平衡困難	穩定收斂
D 預訓練適用性	域不匹配（clean domain → noisy student tokens）	無此問題

結論：MR-STFT + Mel 是 GAN perceptual loss 的**輕量穩定替代品**。

四、訓練設定

4.1 超參數

參數	值	說明
Epochs	300	exp_0224a 設定
Batch Size	8	有效 batch=16（grad_accum=2）
Learning Rate	1e-4 → 1e-6	Cosine Annealing with Warmup

參數	值	說明
Warmup Epochs	5	線性 warmup
Weight Decay	0.01	AdamW
Gradient Clip	1.0	Max norm
AMP	✅	Mixed precision (FP16)
Seed	42	可重現

4.2 資料增強

增強方式	機率	參數
SNR Remix	50%	range: [-5, 25] dB
Random Gain	30%	±3 dB
Random Crop	30%	min ratio: 0.7
Time Stretch	20%	range: [0.95, 1.05]

4.3 Encoder LoRA 配置（exp_0224a）

```
LoRA rank:   64
LoRA alpha:  128   (alpha/rank = 2.0)
dropout:     預設（繼承 exp_0217）
target:      Encoder 的指定 Linear 層
init ckpt:   exp_0217/runs/t453_weighted_epoch_20260217_104843/best_model.pt
```

4.4 Decoder LoRA 配置（exp_0224b）

```
LoRA rank:   32
LoRA alpha:  64    (alpha/rank = 2.0)
dropout:     0.1
target:      backbone.ConvNeXtBlock.pwconv1 (768→2304) × 12
             backbone.ConvNeXtBlock.pwconv2 (2304→768) × 12
             共 24 個 Linear 層
init ckpt:   exp_0224a best_model.pt（encoder 部分）
```

4.5 執行流程

```
Step 1: exp_0224a（Encoder LoRA 訓練）
    python exp_0224/train_no_vq.py --mode epoch --epochs 300 --device cuda:0
    → 產出 best_model.pt（encoder LoRA 參數）

Step 2: exp_0224b（Decoder LoRA 訓練，依賴 Step 1）
    python exp_0224/train_no_vq_decoder_lora.py \
        --mode epoch --epochs 300 --device cuda:1 \
        --encoder_ckpt exp_0224/runs/no_vq_epoch_YYYYMMDD_HHMMSS/best_model.pt
```

五、WavTokenizer 原始架構參考

5.1 Decoder 架構

```
WavTokenizer Decoder
├── VQ Codebook Lookup (K=4096, dim=512)  ← exp_0224 跳過此步驟
├── Backbone: VocosBackbone
│   ├── embed (Conv1d: 512 → 768)
│   ├── adanorm_num_embeddings = 1 (bandwidth_id)
│   └── ConvNeXtBlock × 12
│       ├── dwconv    (Conv1d: 768→768, k=7, groups=768)
│       ├── adanorm   (AdaLayerNorm)
│       ├── pwconv1   (Linear: 768 → 2304)    ← LoRA target
│       ├── GELU activation
│       └── pwconv2   (Linear: 2304 → 768)    ← LoRA target
├── Head: FourierHead
│   ├── out (Linear: 768 → 4098)
│   ├── istft (n_fft=2048, hop=300, win=2048)
│   └── 產生 24kHz 波形
```

5.2 Encoder 架構

```
WavTokenizer Encoder (EncodecEncoder variant)
├── 多層 Conv1d downsampling
├── LSTM layers
├── 最終輸出: [B, 512, T_frame]
```

```
│   T_frame = T_wav / (hop_product)
└── LoRA 施加於指定 Linear 層
```

5.3 信號流對比

```
【有 VQ（exp_0217, exp_0223）】
   Audio → Encoder → z_e [B,512,T] → VQ → z_q [B,512,T] → Decoder → Audio
                                          ↑
                                     離散化！K=4096
                                     量化誤差不可避免

【無 VQ（exp_0224）】
   Audio → Encoder → z_e [B,512,T] ──────────────────→ Decoder → Audio
                                          ↑
                                     連續特徵！保留完整信息
                                     梯度可以直接回傳
```

六、實驗進展與初步結果

6.1 exp_0224a 訓練狀態

指標	Epoch 1	Best (Epoch 179)	Latest (Epoch 287)
val_mel_loss	0.8134	**0.7442**	0.7505
val_wav_mse	0.02392	0.02776	0.02950
val_stft_sc	—	0.6608	0.6658
noisy baseline (mel)	1.2013	1.2013	1.2013

觀察： - val_mel 從 0.81 降至 0.74，遠低於 noisy baseline 1.20（**改善 38%**） - 但 val_wav_mse 在後期略上升（0.024 → 0.030），可能出現輕微過擬合 - Best epoch 在 179，之後開始 plateau / 微幅退化 - LR 已降至 1e-6（cosine schedule 末期）

6.2 與 exp_0223 v2 對比

指標	exp_0223 v2 (Decoder LoRA, 有 VQ)	exp_0224a (Encoder LoRA, 無 VQ)
val_mel_loss (early)	~0.84 (epoch 2)	0.81 (epoch 1)

指標	exp_0223 v2 (Decoder LoRA, 有 VQ)	exp_0224a (Encoder LoRA, 無 VQ)
val_mel_loss (best)	待完成	**0.7442**
可訓練參數	2.36M (decoder)	4.72M (encoder)
VQ 瓶頸	有	**無**

6.3 exp_0224b 狀態

尚未啟動。等待 exp_0224a 完成 300 epochs 後，取 best_model.pt 作為 encoder 初始化。

七、科學假設與預期

7.1 核心假設

- **H1**：跳過 VQ 能讓 Encoder LoRA 產生更接近 clean decoder input 的連續特徵，降低 mel loss
- **H2**：exp_0224b（No-VQ + Decoder LoRA）應優於 exp_0223 v2（有 VQ + Decoder LoRA），因為 decoder 接收的是更高品質的連續 feature
- **H3**：如果 exp_0224a 比 exp_0217（有 VQ + Encoder LoRA + feature MSE）的 PESQ 更高，則證明 VQ 確實是主要瓶頸

7.2 預期結果排序

```
PESQ 排序預期（高到低）：
  exp_0224b (No-VQ + Decoder LoRA)
  > exp_0224a (No-VQ + Encoder LoRA)
  > exp_0223 v2 (VQ + Decoder LoRA)
  > exp_0217 (VQ + Encoder LoRA + Feature MSE)
  > Noisy baseline
```

7.3 失敗模式分析

風險	症狀	對策
連續特徵域漂移	Decoder 接收 OOD 輸入，輸出雜訊	加 feature norm / 約束 encoder output range
Encoder 過擬合		

風險	症狀	對策
	val loss 上升 (已觀察到輕微跡象)	Early stopping / 降低 LR / 加 regularization
Decoder LoRA 不穩定	exp_0224b loss 震盪	降低 decoder LR / warmup 更長

八、檔案結構

```
exp_0224/
├── ARCHITECTURE.md            ← 本文件
├── models_no_vq.py            ← exp_0224a 模型（TeacherStudentNoVQ）
├── models_no_vq_decoder_lora.py  ← exp_0224b 模型
（TeacherStudentNoVQDecoderLoRA）
├── train_no_vq.py             ← exp_0224a 訓練腳本 (854 lines)
├── train_no_vq_decoder_lora.py  ← exp_0224b 訓練腳本 (819 lines)
└── runs/
    └── no_vq_epoch_20260223_055458/  ← exp_0224a 訓練產出
        ├── config.json           ← 超參數快照
        ├── history.json          ← 逐 epoch metrics
        ├── best_model.pt         ← val_mel_loss 最佳 checkpoint
        ├── checkpoint_epoch*.pt  ← 每 10 epoch 備份
        ├── training_curves_*.png ← 每 25 epoch 曲線圖
        ├── audio_samples/        ← 評估音訊樣本
        └── train.log             ← 完整訓練日誌
```

九、如何重現

```python
# 環境（conda env "test"）
conda activate test

# Step 1: exp_0224a — Encoder LoRA + No-VQ
python exp_0224/train_no_vq.py \
    --mode epoch \
    --epochs 300 \
    --device cuda:0 \
    --encoder_ckpt exp_0217/runs/t453_weighted_epoch_20260217_104843/
        best_model.pt \
```

```
    --lora_rank 64 \
    --lora_alpha 128 \
    --lambda_wav 1.0 \
    --lambda_stft 1.0 \
    --lambda_mel 45.0 \
    --batch_size 8 \
    --grad_accum 2 \
    --lr 1e-4

# Step 2: exp_0224b — Decoder LoRA + No-VQ（需先完成 Step 1）
python exp_0224/train_no_vq_decoder_lora.py \
    --mode epoch \
    --epochs 300 \
    --device cuda:1 \
    --encoder_ckpt exp_0224/runs/no_vq_epoch_20260223_055458/best_model.pt \
    --decoder_lora_rank 32 \
    --decoder_lora_alpha 64
```